

Aplicação de Método Heurístico para Decifração de Mensagens Utilizando Python

1st Marco Mello

Arquitetura de Computadores

Programa de Pós-Graduação em Ciência da Computação - UFABC

Santo André, Brasil

marcomello.e@gmail.com

Abstract—This study presents the development and application of a heuristic method for the automated decryption of encoded messages. The proposed approach employs the Python programming language to implement a processing pipeline that converts binary sequences into ASCII characters, performs frequency analysis, and applies iterative mappings between encoded symbols and alphabetic letters. The encrypted messages used in this study are written in English, which makes understanding the linguistic structure of the English language fundamental to the decryption process. The system operates incrementally, testing combinations of one-, two-, and three-letter patterns and refining mappings according to detected language patterns. This methodology enables the gradual reconstruction of the original text, visually highlighting decoded segments. The results demonstrate the effectiveness of frequency-based and positional heuristic analysis for assisting in the interpretation of English-encoded messages through structured and reproducible computational processes.

Keywords: decryption; heuristic method; frequency analysis; Python; cryptanalysis; English language; encoded messages.

Index Terms—Decryption, Frequency Analysis, Classical Cryptography, Python, ASCII, Automation

I. INTRODUÇÃO

O avanço da computação e o aumento da capacidade de processamento têm possibilitado o desenvolvimento de ferramentas cada vez mais sofisticadas para análise e interpretação de dados cifrados. A decifração de mensagens, antes restrita ao campo da criptografia clássica e à atuação de especialistas, tornou-se também um desafio computacional, envolvendo métodos heurísticos, estatísticos e linguísticos. Neste contexto, a linguagem Python destaca-se como uma das principais plataformas para o desenvolvimento de soluções automatizadas, devido à sua versatilidade, clareza sintática e ampla disponibilidade de bibliotecas voltadas à manipulação de dados e textos.

O presente trabalho tem como objetivo apresentar a implementação de um método heurístico para a decifração de mensagens codificadas, utilizando Python como ferramenta principal. O método desenvolvido baseia-se em análise de frequência e mapeamento posicional de caracteres, aplicando substituições progressivas para reconstruir o texto original. O processo parte de uma sequência binária, na qual cada grupo de bits representa um caractere em código ASCII, passando por etapas de conversão, tokenização e organização até atingir a fase de decifração heurística.

As mensagens analisadas encontram-se originalmente em língua inglesa, o que torna indispensável o conhecimento das estruturas linguísticas do idioma para a correta interpretação dos resultados. A identificação de padrões comuns, como palavras curtas de alta frequência, permite que o sistema aprimore o mapeamento de caracteres de forma iterativa, aumentando gradualmente o percentual de texto decifrado.

A abordagem proposta não busca substituir algoritmos criptográficos formais, mas sim demonstrar como técnicas heurísticas e princípios básicos de análise de frequência podem ser aplicados a problemas de decifração em nível computacional. Dessa forma, este estudo contribui para o entendimento prático dos fundamentos da criptanálise e evidencia o potencial do Python na implementação de métodos experimentais de decodificação automatizada.

II. REFERENCIAL TEÓRICO

A decifração de mensagens e o estudo de padrões linguísticos têm sido temas recorrentes tanto na literatura quanto na ciência da computação. O desenvolvimento de métodos heurísticos de análise, como o apresentado neste trabalho, é inspirado em abordagens históricas e conceituais que unem raciocínio lógico, estatística e linguística.

A. Criptanálise e o contexto histórico

O filme *O Jogo da Imitação* (2014), dirigido por Morten Tyldum, apresenta uma dramatização da trajetória de Alan Turing e sua equipe durante a Segunda Guerra Mundial, quando se dedicaram à quebra da cifra Enigma. Embora o presente estudo não utilize o mesmo modelo matemático ou criptográfico, a obra ilustra com clareza o papel do pensamento heurístico e da automação na decifração de mensagens complexas. A construção de máquinas de análise e a busca por padrões recorrentes — sejam repetições, combinações de letras ou comportamentos probabilísticos — servem como base conceitual para o método desenvolvido neste trabalho. Assim como Turing, que aplicava raciocínio lógico aliado à observação de frequência e contexto, o sistema proposto aqui utiliza análise estatística e inferência linguística para aproximar-se de uma solução.

B. Criptoanálise na literatura: O Escaravelho de Ouro

O conto *O Escaravelho de Ouro*, de Edgar Allan Poe (1843), é frequentemente citado como um dos primeiros exemplos

literários de análise criptográfica. Na narrativa, o protagonista decifra uma mensagem cifrada por substituição simples utilizando observação de padrões e contagem de frequência de letras — metodologia que antecipa, em essência, técnicas modernas de criptoanálise. Edgar Allan Poe demonstra que o entendimento da língua e a identificação de letras ou palavras recorrentes são chaves para a interpretação de mensagens ocultas. Esse mesmo princípio fundamenta o método aqui implementado, no qual o reconhecimento de tokens curtos e de alta frequência serve como ponto de partida para reconstruir o texto original.

C. Análise de frequência e dados linguísticos em inglês

A análise de frequência constitui o núcleo estatístico da criptoanálise clássica. No contexto deste trabalho, a frequência relativa de palavras e letras na língua inglesa é utilizada para estimar probabilidades e orientar o mapeamento de caracteres. Como referência, foi considerado o estudo conduzido por Peter Norvig [4], que atualiza e amplia os resultados clássicos de Mayzner e Tresselt sobre a frequência de palavras no inglês contemporâneo. Esse levantamento oferece uma base quantitativa sólida para a construção de um banco de palavras ordenado por probabilidade de ocorrência, permitindo ao sistema atribuir maior prioridade a combinações de letras mais prováveis durante o processo de decifração.

D. Síntese teórica

O referencial teórico que sustenta este estudo, portanto, combina três dimensões complementares: a inspiração histórica da criptoanálise e da automação lógica (*O Jogo da Imitação*), a demonstração literária do raciocínio por frequência (*O Escaravelho de Ouro*) e a fundamentação empírica de padrões linguísticos contemporâneos (Norvig, 2012). Essa integração entre lógica, literatura e estatística reflete a natureza interdisciplinar da criptoanálise moderna e orienta a formulação do método heurístico implementado em Python neste trabalho.

III. METODOLOGIA

A metodologia desenvolvida neste trabalho foi estruturada em um pipeline automatizado de decifração, implementado em linguagem Python. O processo combina etapas de pré-processamento de dados, análise de frequência, mapeamento posicional e aplicação iterativa de substituições, com o objetivo de reconstruir o texto original a partir de uma mensagem codificada em binário.

O sistema foi projetado para operar de forma modular, permitindo a inspeção manual de cada etapa e a geração de artefatos intermediários que documentam o progresso do mapeamento de caracteres. A seguir, são detalhadas as principais etapas do método.

A. Arquitetura geral do processo

O método inicia-se com a leitura de um arquivo contendo a mensagem em formato binário, em que cada sequência de bits representa um caractere ASCII. Essa entrada é convertida

para texto legível, tokenizada e reorganizada em uma estrutura matricial que associa cada palavra à sua posição original. Em seguida, essa matriz é ordenada por comprimento e frequência de ocorrência, permitindo priorizar tokens curtos e recorrentes — elementos essenciais para o início do processo heurístico de decifração. A Figura 1 apresenta o fluxo geral do pipeline de decifração, destacando as principais etapas do processo, desde a leitura do arquivo binário até a exportação do texto final decifrado. O diagrama ilustra a sequência lógica de operações, as decisões envolvidas e os pontos de iteração do método.




Fig. 1. Fluxograma do pipeline heurístico de decifração implementado em Python.

O processo é dividido em cinco macroetapas principais:

- 1) **Leitura e conversão:** o arquivo binário é importado e convertido para caracteres ASCII, gerando uma primeira versão textual da mensagem;
- 2) **Tokenização e normalização:** o texto é dividido em tokens (palavras, símbolos e pontuações), cada um sendo indexado pela posição original no arquivo;
- 3) **Ordenação de tokens:** as palavras são agrupadas por comprimento e frequência, permitindo priorizar aquelas mais curtas e mais comuns na língua inglesa;
- 4) **Mapeamento heurístico:** o algoritmo aplica mapeamentos parciais e progressivos de caracteres, testando diferentes hipóteses linguísticas;
- 5) **Análise e avaliação:** cada decifrado parcial é avaliado conforme a porcentagem de letras mapeadas e a presença de palavras reconhecidas no banco de frequência.

B. Heurística de mapeamento incremental

O núcleo do método é a heurística incremental de decifração, estruturada em três fases principais. Essa abordagem foi projetada para imitar a lógica da criptoanálise clássica baseada em frequência e contexto linguístico, aplicando substituições progressivas com base em padrões esperados do inglês.

1) *Etapla 1 – Mapeamento de palavras de uma letra:* O processo inicia-se com a identificação das menores palavras existentes na língua inglesa — as vogais isoladas *A* e *I*. Como essas palavras são altamente frequentes e possuem um significado próprio, elas constituem um ponto de partida de alta confiabilidade para estabelecer as primeiras correspondências entre caracteres codificados e letras do alfabeto. O algoritmo busca tokens de um único caractere e aplica mapeamentos diretos, gerando os primeiros arquivos de texto parcialmente decifrados.

2) *Etapla 2 – Palavras de duas letras com letras conhecidas:* Com base nos mapeamentos obtidos na fase anterior, o sistema passa a analisar palavras de duas letras que contenham as letras já mapeadas (por exemplo, *AS*, *AT*, *IN*, *IS*). Nessa etapa, o objetivo é estender o dicionário de substituições utilizando o contexto posicional. O algoritmo aplica uma série de subloops, testando diferentes combinações e avaliando a correspondência com palavras reais da língua inglesa. Essa análise é auxiliada por um banco de palavras (*top_words_banco_de_palavras*) que fornece as palavras mais frequentes e suas respectivas probabilidades de ocorrência.

3) *Etapla 3 – Fallback com palavras de três letras:* Caso as etapas anteriores não resultem em uma decifração satisfatória, o sistema executa uma etapa de fallback baseada em palavras de três letras de alta frequência, como *THE*, *AND*, *FOR*, *NOT*, entre outras. Essas palavras são aplicadas sequencialmente, testando compatibilidade com o mapeamento atual e refinando a substituição de caracteres. A análise é repetida de forma iterativa até que não haja novos ganhos de cobertura no texto decifrado.

C. Critérios de avaliação

Cada iteração do processo gera um arquivo intermediário de saída contendo o texto parcialmente decifrado. O sistema calcula automaticamente duas métricas principais:

- **Percentual de palavras reconhecidas:** razão entre o número de palavras existentes no banco de frequência e o total de palavras detectadas no texto;
- **Percentual de texto traduzido:** proporção de caracteres que foram efetivamente substituídos por letras minúsculas (indicando mapeamento realizado).

A combinação dessas métricas permite identificar o estágio mais avançado de decifração e selecionar o melhor resultado final, exportado como arquivo de texto contínuo.

D. Ferramentas e implementação

Toda a implementação foi realizada em Python, utilizando exclusivamente bibliotecas nativas, sem dependências externas. O sistema organiza automaticamente seus arquivos de trabalho em pastas específicas (*mensagens*, *mapeamentos*, *decifrados* e *palavrasUsadas*), o que facilita a inspeção manual e o acompanhamento do progresso de cada etapa do processo. Além disso, cada mapeamento é salvo em formato *.py*, permitindo reuso, análise incremental e auditoria do pipeline de decifração.

O código-fonte completo do projeto, incluindo os scripts *decrypt.py* e *funcoes_decodificador.py*, está disponível publicamente no repositório GitHub do autor, acessível em:

https://github.com/Marco-Mello/artigo_01

Esse repositório contém todos os arquivos necessários para a execução do método, bem como exemplos de mensagens codificadas, banco de palavras e diagramas do pipeline de decifração.

IV. RESULTADOS

A execução do método heurístico proposto resultou na decifração progressiva das mensagens codificadas, demonstrando a eficácia do pipeline automatizado em Python. A cada etapa, o sistema gerou arquivos intermediários que documentam o avanço do mapeamento e o aumento do percentual de caracteres traduzidos.

A. Estrutura de processamento

Durante a execução, foram gerados automaticamente quatro diretórios principais: *mensagens/*, *mapeamentos/*, *decifrados/* e *palavrasUsadas/*. Essa organização modular facilita a reprodutibilidade e o acompanhamento da evolução do processo, armazenando versões intermediárias do texto e os mapeamentos aplicados.

B. Progresso por etapa

O método inicia pelo mapeamento de palavras de uma letra (*A* e *I*), ampliando para combinações de duas letras (*AS*, *AT*, *IN*, *IS*) e, em seguida, aplicando o fallback de três letras (*THE*, *AND*, *FOR*, *NOT*). Essa sequência resultou em traduções cada

vez mais completas, evidenciando o ganho de cobertura obtido pela heurística incremental baseada em frequência.

O *fallback* é acionado de forma condicional, quando as etapas iniciais (de uma e duas letras) não produzem novos mapeamentos válidos ou não aumentam o percentual de tradução. Nessa situação, o sistema executa automaticamente uma etapa de recuperação baseada em palavras curtas e altamente frequentes na língua inglesa. Essa abordagem visa destravar o processo de decifração, introduzindo novos pares de substituição a partir de termos universais como *THE*, *AND* e *FOR*. A aplicação dessas palavras permite expandir o dicionário de mapeamento e revelar novos padrões linguísticos, elevando substancialmente a taxa de cobertura do texto e restabelecendo o progresso do pipeline quando este se encontra estagnado.




Fig. 2. Fluxo resumido das etapas do pipeline heurístico de decifração: mapeamento de uma letra, duas letras e fallback de três letras.

C. Métricas e desempenho

A avaliação considerou:

- **Palavras reconhecidas:** percentual de tokens válidos segundo o banco de palavras;
- **Texto traduzido:** proporção de caracteres efetivamente decifrados.

O processo mostrou crescimento contínuo nessas métricas, alcançando traduções entre 75 % e 100 % conforme o nível de redundância e previsibilidade do texto cifrado.

D. Resultados com o banco de palavras de Peter Norvig

Para validar o método, os arquivos `encoded_01.txt` e `encoded_02.txt` foram decifrados utilizando o banco de palavras de alta frequência de Peter Norvig [4], referência estatística do inglês contemporâneo. A seguir, são apresentados os textos resultantes das decifrações realizadas com o dicionário base.

Arquivo `encoded_01.txt`:

*"the daD we ceabe the ePJloration oG the cobQob
ib the daD we threaten the continuinR oG our
bJecieb in that XleaY world arQb XearinR rebource
hunRrD JeoJle and nationb would Xe Jrone to act
on their low contracted JreLudiceb and would have
been the labt RabJ oG huQan enliRhthenQent until
the ribe oG a vibionarD new culture that once aRain
eQXrcebe the cobQic JerbJective a JerbJective in
which we are one GittinR neither aXove nor Xelow
Xut within."*

O texto apresenta trechos parcialmente compreensíveis, já com estrutura sintática coerente e correspondência linguística clara, demonstrando o avanço do mapeamento mesmo com ruído residual de substituições incorretas.

Arquivo `encoded_02.txt`:

*"looT aFain at that dot . that ' s here . that ' s home
. that ' s us . on it everyone you love , everyone
you Tnow , everyone you ever heard of , every
human beinF who ever was , lived out their lives .
the aFFreFate of our Voy and sufferinF , thousands
of confident reliFions , ideoloFies , and economic
doctrines , every hunter and foraFer , every hero and
coward , every creator and destroyer of civiliEation
, every TinF and Geasant , every younF couGle
in love , every mother and father , hoGeful child
, inventor and ePGlorer , every teacher of morals
, every corruGt Golitician , every " suGerstar , "
every " suGreme leader , " every saint and sinner
in the history of our sGecies lived there – on a
mote of dust susGended in a sunbeam . the earth
is a very small staFe in a vast cosmic arena . thinT
of the rivers of blood sGilled by all those Fenerals
and emGerors so that , in Flory and triumGh , they
could become the momentary masters of a fraction
of a dot . thinT of the endless cruelties visited by
the inhabitants of one corner of this GiPel on the
scarcely distinFuishable inhabitants of some other
corner , how freRuent their misunderstandinFs , how
eaFer they are to Till one another , how fervent
their hatreds . our GosturinFs , our imaFined self*

- imGortance , the delusion that we have some GrivileFed Gosition in the universe , are challenFed by this Goint of Gale liFht . our Glanet is a lonely sGecT in the Freat enveloGinF cosmic darT . in our obscurity , in all this vastness , there is no hint that helG will come from elsewhere to save us from ourselves . the earth is the only world Tnown so far to harbor life . there is nowhere else , at least in the near future , to which our sGecies could miFrate . visit , yes . settle , not yet . liTe it or not , for the moment the earth is where we maTe our stand . it has been said that astronomy is a humblinF and character - buildinF ePGerience . there is GerhaGs no better demonstration of the folly of human conceits than this distant imaFe of our tiny world . to me , it underscores our resGonsibility to deal more Tindly with one another , and to Greserve and cherish the Gale blue dot , the only home we ' ve ever Tnown .”

Este segundo texto revela uma decifração praticamente completa, ainda que com pequenas variações de caracteres, demonstrando a robustez da heurística implementada.

Arquivo	Palavras (%)	Tradução (%)
encoded_01.txt	36.25	88.56
encoded_02.txt	40.54	95.42

Tabela I
RESULTADOS COM O BANCO DE PALAVRAS DE PETER NORVIG.

Após a decifração, os textos foram pesquisados na internet para identificar possíveis correspondências com textos originais, já que a origem dos textos não era conhecida.

O primeiro texto decifrado foi comparado com a letra da música *Exist*, da banda *Avenged Sevenfold* [6]. A comparação revelou uma compatibilidade substancial, com a maioria das palavras sendo reconhecíveis, embora com pequenas variações de caracteres, como esperado em um processo de decifração heurística. A estrutura e a gramática geral do texto estavam em conformidade com o tema e o estilo da música, validando a eficiência da heurística aplicada.

O segundo texto foi identificado como o famoso discurso *Pale Blue Dot*, de Carl Sagan [7], após uma pesquisa na internet. A comparação com a transcrição original disponível online revelou uma correspondência impressionante, com a decifração atingindo um alto grau de precisão. A tradução das palavras e a fluidez do texto gerado mostraram-se praticamente idênticas ao texto original, com exceção de algumas variações menores, o que reforça a precisão do método heurístico para textos complexos e significativos.

Essas comparações mostram que o sistema foi capaz de decifrar sequências de caracteres e associá-las a textos conhecidos, validando a aplicação da heurística. Embora com algumas variações, os textos decifrados apresentaram uma boa correspondência com os originais, indicando a efetividade

do método em identificar e recuperar textos de significado relevante.

E. Resultados com banco de palavras expandido

Na etapa seguinte, o dicionário foi ampliado com termos ausentes, mas recorrentes nas mensagens analisadas: As novas palavras adicionadas estão diretamente relacionadas ao conteúdo dos textos analisados:

- **Texto 1:** DAY, ARMS, BLEAK, CEASE, SPECIES, EXPLORATION, ENLIGHTENMENT;
- **Texto 2:** JOY, KINDLY, EXPLORER, FREQUENT, CIVILIZATION, RESPONSIBILITY, DISTINGUISHABLE.

Essas inclusões aprimoraram o resultado do mapeamento de caracteres, reduzindo as lacunas de tradução observadas.

Arquivo	Banco	Palavras (%)	Tradução (%)	Ganhos
encoded_01.txt	Norvig	36.25	88.56	+12.5% / +9.8%
	Expandido	48.75	98.40	
encoded_02.txt	Norvig	40.54	95.42	+2.4% / +4.6%
	Expandido	42.97	100.00	

Tabela II
COMPARATIVO ENTRE O BANCO DE NORVIG E O BANCO EXPANDIDO.

O ajuste do banco de palavras foi realizado a partir da análise dos resultados anteriores, identificando termos que o mapeamento inicial não havia reconhecido. Sabendo-se, a partir de pesquisas posteriores, quais eram os textos provavelmente representados, as novas palavras foram escolhidas para cobrir lacunas específicas e melhorar a coerência geral das decifrações. Essas inclusões proporcionaram ganhos, embora modestos, de precisão: o texto 1 alcançou 98,4% de tradução, enquanto o texto 2 atingiu 100%, com todas as letras do alfabeto mapeadas. Apesar da melhora observada, o impacto na qualidade geral da decifração não foi expressivo, indicando que o sistema já apresentava um bom desempenho antes da expansão do vocabulário.

F. Síntese dos resultados

O método proposto apresentou robustez e consistência entre diferentes mensagens, mantendo alta taxa de reconstrução textual. A integração de frequência estatística e heurística posicional provou ser uma estratégia eficiente para a decifração de mensagens binárias, e a inclusão de vocabulário contextual reforçou a completude semântica dos textos finais.

V. CONCLUSÃO

O presente trabalho apresentou o desenvolvimento e a aplicação de um método heurístico para a decifração automatizada de mensagens codificadas, implementado integralmente em linguagem Python. O sistema foi projetado para operar de forma iterativa, aplicando análise de frequência e mapeamento posicional a partir de dados binários convertidos em caracteres ASCII.

A abordagem proposta demonstrou que é possível, por meio de técnicas heurísticas simples e de raciocínio incremental, reconstruir parcialmente mensagens cifradas sem recorrer a métodos criptográficos complexos. A sequência lógica adotada

— iniciando com palavras de uma letra, expandindo para palavras de duas letras e utilizando palavras de três letras como fallback — mostrou-se eficaz na obtenção de correspondências linguísticas progressivas. Essa estratégia permitiu a identificação gradual de padrões, evidenciando a importância de uma análise guiada por frequência e contexto.

Os resultados obtidos comprovam a viabilidade da aplicação da heurística de análise de frequência como ferramenta computacional de decifração. O sistema apresentou evolução consistente nas métricas de desempenho, com aumento contínuo do percentual de texto traduzido e de palavras reconhecidas. Além disso, a estrutura modular e transparente do código facilita a reprodução dos experimentos e a adaptação do método para diferentes conjuntos de dados.

Como perspectivas futuras, propõe-se a ampliação do banco de palavras de referência, a inclusão de análises baseadas em bigramas e trigramas, e a adaptação do método para outros idiomas, de forma a expandir o alcance da abordagem. Também se sugere o desenvolvimento de uma interface gráfica que permita o acompanhamento visual do processo de decifração, tornando a ferramenta mais acessível para uso educacional e de pesquisa.

Em síntese, o método desenvolvido neste trabalho reafirma o potencial das abordagens heurísticas aplicadas à criptanálise, demonstrando que a combinação entre linguística computacional, estatística e automação em Python pode gerar resultados significativos na interpretação de mensagens codificadas.

REFERÊNCIAS

- [1] M. Tyldum (Director), *The Imitation Game* [Film]. Los Angeles, CA: Black Bear Pictures, 2014.
- [2] E. A. Poe, *The Gold-Bug*. Philadelphia, PA: Dollar Newspaper, 1843.
- [3] L. Possani, “Criptografia: das origens à obra de Edgar Allan Poe,” disponível em: <https://www.youtube.com/watch?v=Kw5msUWSIms>, acessado em: Outubro/2025.
- [4] P. Norvig, “English Letter Frequency Counts: Mayzner Revisited or ETAOIN SRHLDKU,” disponível em: <https://norvig.com/mayzner.html>, acessado em: Outubro/2025.
- [5] English Experts, “As palavras mais comuns da língua inglesa,” disponível em: <https://www.englishexperts.com.br/wp-content/uploads/downloads/as-palavras-mais-comuns-da-lingua-inglesa.pdf>, acessado em: Outubro/2025.
- [6] Avenged Sevenfold, *Exist*, no álbum *The Stage*. Capitol Records, 2016.
- [7] C. Sagan, *Pale Blue Dot: A Vision of the Human Future in Space*. New York: Random House, 1994.